CHALLENGE DATA ENGINEER ARTEFACT

Comprendre le métier derrière le challenge

Banque, assurance, mobile money, microfinance, données et indicateurs

Objectif : comprendre ce que représentent réellement les tables et les colonnes, comment les activités de WABA fonctionnent et pourquoi les KPI demandés ont du sens.

1. Le contexte métier

WABA est un groupe financier fictif présent dans huit pays d'Afrique de l'Ouest : Côte d'Ivoire, Sénégal, Mali, Burkina Faso, Guinée, Togo, Bénin et Ghana. Il rassemble plusieurs métiers qui, dans une vraie entreprise, utilisent des applications différentes.

Métier	Ce que fait l'entreprise	Exemples de données
Banque de détail	Comptes courants, épargne et crédits aux particuliers.	Clients, comptes, virements, retraits, dépôts, remboursements.
Banque entreprise	Financement et services de trésorerie pour les sociétés.	Clients corporate, gros virements, crédits, frais.
Assurance	Vend des contrats et indemnise les sinistres couverts.	Primes, polices, déclarations, paiements de sinistres.
Mobile money	Permet d'envoyer, recevoir et payer depuis un portefeuille numérique.	Expéditeur, destinataire, opérateur, statut, frais.
Microfinance	Accorde de petits crédits à des populations ou activités moins servies par la banque classique.	Microcrédits, échéances, retards, défauts.

Le vrai problème de WABA

Chaque métier et chaque pays peut avoir son propre système. La direction ne dispose donc pas spontanément d'une vue unique des revenus, des risques et de la conformité. La plateforme du challenge sert à réunir ces informations sans perdre leur origine.

> **Le challenge n'est pas seulement de déplacer des fichiers. Il faut reconstruire une vision commune d'activités financières différentes.**

2. Les dimensions communes : pays et entité

Deux colonnes doivent apparaître partout car elles permettent de comparer les activités.

Colonne	Signification métier	Pourquoi elle est essentielle
country_code	Pays auquel la donnée est rattachée, au format ISO : CI, SN, ML, BF, GN, TG, BJ ou GH.	Filtrer, consolider, appliquer la bonne devise et limiter l'accès d'un analyste à son pays.
entity_type	Ligne métier : BANK, INSURANCE, MOBILE_MONEY ou MICROFINANCE.	Séparer les activités et consolider le groupe sans les confondre.

Pays, devise et réglementation

- CI, SN, ML, BF, GN, TG et BJ sont traités dans le challenge avec la devise XOF.
- Le Ghana utilise GHS.
- Les montants Silver sont convertis en EUR pour comparer les pays dans une même unité.
- Les indicateurs réglementaires concernent notamment la BCEAO pour la banque et la CIMA pour l'assurance.

Une donnée peut appartenir à plusieurs axes simultanément : une opération peut être au Ghana, concerner la banque, provenir d'une agence d'Accra et porter sur un client Corporate.

3. Référentiel ou transaction : la distinction fondamentale

Concept	Définition simple	Exemples
Référentiel	Liste relativement stable des objets connus par l'entreprise.	Clients, comptes, agences, produits.
Transaction / événement	Action datée qui s'est produite dans l'activité.	Virement, paiement, sinistre, remboursement.

Pourquoi les référentiels viennent d'abord

Une opération n'a de sens que si ses acteurs existent. Avant de créer un virement, WABA doit connaître le compte débité, le compte bénéficiaire et éventuellement l'agence d'origine. Avant de créer un remboursement, WABA doit connaître le client et son compte de prêt.

customers -> accounts -> transactions. branches -> transactions. products -> comptes, opérations et analyses.

Clé primaire et clé étrangère

- Une clé primaire identifie une ligne de manière unique : customer_id identifie un client.
- Une clé étrangère référence une ligne d'une autre table : accounts.customer_id indique le propriétaire du compte.
- Une transaction orpheline contient une clé étrangère qui ne mène à aucune ligne existante. Elle est interdite ici.

4. customers.csv - les clients

Cette table représente les personnes ou organisations qui entretiennent une relation avec WABA.

Colonne	Sens métier détaillé
customer_id	Identifiant fictif unique du client. Il sert de lien avec ses comptes et opérations.
country_code	Pays principal de rattachement du client.
entity_type	Métier WABA qui gère cette relation client.
segment	RETAIL = particulier; SME = petite/moyenne entreprise; CORPORATE = grande entreprise; PREMIUM = client à forte valeur.
kyc_level	Niveau de vérification Know Your Customer : BASIC, STANDARD ou ENHANCED. Plus le risque ou les services sont élevés, plus la vérification est approfondie.
onboarding_date	Date à laquelle le client a commencé sa relation avec WABA.
region	Zone géographique ou ville de rattachement.
is_active	Indique si la relation est encore active.

Utilité analytique

Le segment permet de calculer l'ARPU par type de clientèle. Le niveau KYC aide à comprendre le niveau de contrôle appliqué. Le statut actif permet d'éviter de compter comme utilisateurs actifs des clients fermés ou inactifs.

5. accounts.csv - les comptes et contrats

Un compte matérialise le produit détenu par un client. Dans l'annexe, la notion est large : elle couvre un compte bancaire, un prêt, un wallet mobile ou une police d'assurance.

Colonne	Sens métier détaillé
account_id	Identifiant unique du compte ou contrat.
customer_id	Propriétaire; il doit exister dans customers.
country_code	Pays de tenue du compte.
account_type	CURRENT = courant; SAVINGS = épargne; LOAN = prêt; MOBILE_WALLET = portefeuille mobile; INSURANCE_POLICY = police.
currency	Devise du solde et des opérations : XOF ou GHS.
balance	Solde courant disponible ou position financière du compte.
credit_limit	Montant maximal de crédit autorisé; zéro lorsqu'il n'est pas applicable.
opened_date	Date d'ouverture, nécessairement antérieure aux opérations du compte.
status	ACTIVE, FROZEN, CLOSED ou DORMANT. Le statut influence les opérations autorisées.

Cohérence métier : un remboursement doit viser un account_type=LOAN; une opération d'assurance doit viser une police; un paiement mobile doit impliquer des clients ou wallets compatibles.

6. branches.csv et products.csv

branches décrit les points de service. products décrit le catalogue commercial. L'annexe visible détaille branches, mais donne seulement le nom products.csv et un volume de 50 produits. Le schéma de products doit donc être défini et documenté sans inventer plus que nécessaire.

Colonne branches	Sens métier
branch_id	Identifiant unique d'une agence ou d'un point de service.
country_code	Pays de l'agence.
entity_type	Métier servi par l'implantation.
city / region	Localisation géographique.
branch_type	FULL_SERVICE, DIGITAL_ONLY, AGENCY_BANKING ou ATM_POINT.
is_active	L'agence peut-elle encore traiter des opérations ?

Rôle probable de products

- Définir un identifiant et un nom de produit.
- Rattacher le produit à un métier et éventuellement à une ligne comme Vie ou IARD.
- Permettre le Top 10 des produits souscrits et les analyses par produit.

Hypothèse à documenter

Comme le schéma détaillé de products n'apparaît pas dans les captures, toute colonne ajoutée doit être présentée comme une hypothèse de modélisation et non comme une exigence explicitement fournie.

7. bank transactions - l'activité bancaire

Colonne	Sens métier
transaction_id	Identifiant UUID unique de l'événement.
timestamp	Date et heure de réalisation.
account_id	Compte débité ou principal.
beneficiary_account	Compte qui reçoit la valeur.
branch_id	Agence ou point d'origine.
country_code	Pays de rattachement de l'opération.
transaction_type	TRANSFER, PAYMENT, WITHDRAWAL, DEPOSIT ou INTERNATIONAL_WIRE.
amount / currency	Montant et devise locale.
channel	BRANCH, ATM, MOBILE_APP, INTERNET_BANKING ou USSD.
transaction_status	SUCCESS environ 92 %, FAILED 5 %, REVERSED 3 %.
fee_amount	Frais facturés; le script indicatif prend 0,1 % pour les succès.
entity_type	BANK ou MICROFINANCE.

Lecture d'un exemple

Une ligne peut signifier : le 10 janvier à 14h32, un compte bancaire ivoirien a effectué un virement de 75 000 XOF par application mobile vers un bénéficiaire; l'opération a réussi et a produit 75 XOF de frais.

Attention : une opération FAILED ne doit normalement pas augmenter les flux financiers réalisés. Une opération REVERSED a été annulée; son traitement analytique doit être défini explicitement.

8. insurance operations - l'activité assurance

Colonne	Sens métier
operation_id / timestamp	Identité et moment de l'opération.
customer_id / account_id	Assuré et police d'assurance concernés.
operation_type	PREMIUM_PAYMENT, CLAIM_SUBMISSION, CLAIM_PAYMENT, POLICY_RENEWAL ou POLICY_CANCELLATION.
product_line	VIE, IARD_AUTO, IARD_HABITATION, IARD_SANTE ou PREVOYANCE.
amount / currency	Prime reçue, indemnité payée ou autre montant selon le type.
claim_status	Pour un sinistre : PENDING, APPROVED, REJECTED ou PAID; sinon NULL.
processing_days	Jours ouvrés nécessaires pour traiter un sinistre; sinon NULL.
entity_type	Toujours INSURANCE.

Prime, sinistre et ratio

- La prime est ce que le client paie pour être couvert.
- Le sinistre est l'événement dommageable déclaré.
- L'indemnité est le montant versé lorsque le sinistre est accepté.
- Loss ratio = sinistres payés / primes acquises. Un ratio élevé signifie que les indemnisations absorbent une grande part des primes.

Règle conditionnelle : claim_status et processing_days n'ont de sens que pour une opération liée à un sinistre.

9. mobile money - wallets et transferts

Colonne	Sens métier
payment_id / timestamp	Identité et moment du paiement.
sender_id	Client expéditeur existant.
receiver_id	Client destinataire existant.
sender_country	Pays d'origine et devise du transfert.
receiver_country	Pays d'arrivée; différent en cas de transfert transfrontalier.
amount / currency	Montant dans la devise de l'expéditeur.
operator	WABA_PAY, ORANGE_MONEY_PARTNER ou MTN_PARTNER.
status	SUCCESS environ 94 %, FAILED 4 %, PENDING 2 %.
fee_amount	Frais de la transaction.
entity_type	MOBILE_MONEY.

Corridor

Un corridor est une paire origine-destination, par exemple CI -> SN. Les corridors servent à mesurer les transferts transfrontaliers, leur montant moyen et leur évolution.

Utilisateur actif

Le KPI doit définir précisément ce terme : par exemple, un sender_id ou receiver_id distinct ayant participé à une transaction réussie pendant la journée.

10. loan repayments - le risque de crédit

Colonne	Sens métier
repayment_id / timestamp	Identité et enregistrement du remboursement.
loan_account_id	Compte existant de type LOAN.
customer_id	Emprunteur propriétaire du prêt.
amount_due	Somme attendue à l'échéance.
amount_paid	Somme réellement reçue; zéro en défaut selon l'annexe.
due_date	Date contractuelle d'échéance.
payment_date	Date réelle; NULL si impayé.
days_overdue	Jours de retard; zéro si payé à temps ou en avance.
loan_type	CONSUMER, MORTGAGE, SME, AGRICULTURAL ou MICROCREDIT.
repayment_status	ON_TIME environ 82 %, LATE 12 %, DEFAULT 6 %.
entity_type	BANK ou MICROFINANCE.

NPL

NPL signifie Non-Performing Loan, ou créance douteuse. La formule demandée est encours des prêts en défaut divisé par encours total. Ce n'est pas simplement le nombre de lignes DEFAULT divisé par le nombre de prêts : il faut comparer des montants d'encours.

Les lignes de remboursement seules peuvent ne pas fournir parfaitement l'encours total d'un prêt. La règle de calcul ou l'enrichissement choisi doit être documenté.

11. Les sept questions métier de Gold

KPI	Question métier	Décision aidée
daily_transaction_volume	Combien d'opérations et quel montant par jour, pays et type ?	Suivre l'activité et les revenus.
npl_ratio_by_country	Quelle part des prêts est en défaut ?	Mesurer le risque de crédit et la conformité BCEAO.
customer_arpu_monthly	Combien de revenus produit un client moyen ?	Comparer pays et segments.
loss_ratio_by_product	Quelle part des primes est consommée par les sinistres ?	Piloter la rentabilité assurance.
claims_processing_time	Combien de jours faut-il pour traiter les sinistres ?	Mesurer la qualité de service.
mobile_money_daily_flow	Quels volumes, montants, échecs et utilisateurs actifs ?	Piloter le réseau mobile money.
cross_border_transfers	Quels corridors reçoivent ou envoient les flux ?	Comprendre les échanges régionaux.

Un KPI a toujours un grain

Le grain est ce que représente exactement une ligne. Une ligne de customer_arpu_monthly représente un mois + un pays + un segment. Si le grain est flou, les doublons et mauvaises sommes deviennent probables.

12. Cohérences métier à tester

Règle	Exemple de donnée invalide
Pays-devise	country_code=GH avec currency=XOF.
Temporalité	Une opération antérieure à opened_date.
Propriété	loan_account_id appartenant à un autre customer_id.
Type de compte	Remboursement sur un compte SAVINGS.
Statut-paiement	DEFAULT avec amount_paid égal au montant dû et payment_date renseignée.
Sinistre	PREMIUM_PAYMENT avec claim_status=PAID.
Agence	branch_id inactif ou d'un pays incompatible sans règle prévue.
Montant	Montant négatif sans signification documentée.
Unicité	Même transaction_id utilisé deux fois.

La qualité métier va plus loin que le type technique

Une valeur peut être techniquement un nombre valide mais métierement impossible. Spark doit donc contrôler les deux niveaux : forme et sens.

13. Le script indicatif fourni

Oui, Artefact fournit un extrait de script de génération et autorise explicitement son adaptation à condition de respecter les schémas et la cohérence référentielle.

Ce qu'il donne déjà

- La liste des pays et la correspondance XOF/GHS.
- Les métiers, segments et probabilités de statuts.
- Des villes par pays.
- Une fonction de date aléatoire.
- Un exemple de génération de clients et de transactions bancaires.
- Une règle indicative de frais : 0,1 % pour une transaction réussie.

Ce qu'il faut adapter ou compléter

- Générer les quatre référentiels et les quatre flux transactionnels.
- Filtrer comptes et agences par pays et par entité.
- Respecter les dates choisies dans Streamlit plutôt que des dates codées en dur.
- Ajouter une seed, des logs et une gestion d'erreurs.
- Produire des scénarios réalistes pour les KPI NPL et loss ratio.
- Envoyer vers MinIO et supporter les modes one-time et continu.

Modifier le code n'est pas contourner l'énoncé : c'est précisément ce que l'annexe autorise. Le contrat à respecter est le schéma métier, pas l'implémentation d'exemple.

14. Résumé métier

Les référentiels décrivent qui et quoi existe. Les événements décrivent ce qui s'est passé. Silver rend les événements comparables. Gold répond aux questions de performance, risque et conformité.

Pour maîtriser le métier, il faut pouvoir raconter une ligne

Exemple : qui est le client ? Quel produit détient-il ? Dans quel pays ? Quelle opération a-t-il réalisée ? Dans quelle devise ? L'opération a-t-elle réussi ? Quel revenu ou risque crée-t-elle ? Dans quel KPI apparaîtra-t-elle ?

Points à ne pas présenter comme certains

- Le schéma détaillé de products n'est pas visible dans les captures.
- La définition exacte des taux EUR n'est pas fournie.
- Certains calculs d'encours ou de primes acquises nécessitent une convention documentée.

Une bonne restitution distingue toujours : exigence explicite, hypothèse raisonnable et choix d'implémentation.