CHALLENGE DATA ENGINEER ARTEFACT

Métier, modèle relationnel et génération

Comprendre les décisions verrouillées avant de construire Streamlit et les pipelines

Ce support relie le contexte métier de WABA, les huit tables, leurs relations, le catalogue produit, les règles de génération, l'interface Streamlit et le stockage MinIO.

1. Le problème métier à résoudre

WABA regroupe plusieurs activités financières dans huit pays : banque, assurance, mobile money et microfinance. Dans une entreprise réelle, ces métiers produisent leurs données dans des systèmes différents : core banking, système d'assurance, API mobile money, applications de crédit et outils d'agence.

Système simulé	Données principales	Fichier produit dans le challenge
Core Banking	Comptes, virements, paiements, retraits, dépôts	bank_txn_[CC]_YYYYMMDD_NN.csv
Assurance	Primes, polices, sinistres, indemnisations	insurance_ops_[CC]_YYYYMMDD_NN.csv
Mobile Money	Paiements, transferts, opérateurs et statuts	mobile_money_[CC]_YYYYMMDD_NN.csv
Crédit	Échéances, remboursements, retards et défauts	loan_repayments_[CC]_YYYYMMDD_NN.csv

La plateforme doit unifier sans mélanger

Les événements restent dans des tables propres à leur métier, mais utilisent des dimensions communes comme le pays, l'entité, le client, le compte et la date. Cela permet de consolider les revenus, risques et indicateurs sans perdre le sens de chaque activité.

> **Unifier signifie rendre les données compatibles, fiables et comparables. Cela ne signifie pas placer tous les événements dans une seule table.**

2. Ce que Streamlit simule

Streamlit n'est pas réellement connecté à T24 ou aux systèmes WABA. Il joue le rôle d'un portail de simulation. L'utilisateur choisit les paramètres et un moteur Python produit les extractions CSV fictives.

Streamlit -> paramètres -> moteur Python -> CSV -> MinIO raw-landing

Sélection	Question à laquelle elle répond	Exemple
Type de données	Que faut-il générer ?	BANK_TRANSACTIONS
Pays	Où l'activité a-t-elle lieu ?	CI, SN, GH
Ligne métier	Quelle activité WABA possède la donnée ?	BANK
Volume	Combien de lignes par pays ?	10 000
Période	Sur quelles dates simuler l'activité ?	Trois mois glissants
Mode	Une fois ou régulièrement ?	ONE_TIME ou CONTINUOUS

Responsabilités séparées

- Streamlit collecte et valide les choix.
- Le moteur Python applique les règles métier et génère les données.
- Le client MinIO dépose le fichier au bon emplacement.

3. Type de données, pays et ligne métier

Ces trois axes ne doivent pas être confondus.

Axe	Signification	Valeurs
data_type	Nature du fichier ou de l'événement	Référentiels, banque, assurance, mobile money, remboursements
country_code	Pays de rattachement	CI, SN, ML, BF, GN, TG, BJ, GH
entity_type	Grande ligne métier WABA	BANK, INSURANCE, MOBILE_MONEY, MICROFINANCE
segment	Catégorie commerciale du client	RETAIL, SME, CORPORATE, PREMIUM
account_type	Catégorie du compte ou contrat	CURRENT, SAVINGS, LOAN, MOBILE_WALLET, INSURANCE_POLICY

Exemple complet

country_code=CI, entity_type=BANK, segment=CORPORATE, account_type=CURRENT et transaction_type=INTERNATIONAL_WIRE signifie qu'une entreprise Corporate rattachée à WABA Banque en Côte d'Ivoire réalise un virement international depuis un compte courant.

4. Référentiel ou transaction

Catégorie	Rôle	Tables
Référentiel	Décrit ce qui existe avant l'événement	customers, accounts, branches, products
Transaction	Décrit ce qui s'est produit à une date donnée	bank_transactions, insurance_operations, mobile_money_payments, loan_repayments

Ordre obligatoire

> **Produits, clients, agences et comptes -> puis transactions**

Une transaction ne crée pas ses propres références. Elle choisit uniquement des clés déjà présentes dans les référentiels. Cette règle évite les clients, comptes ou agences orphelins.

Clé primaire et clé étrangère

- La clé primaire identifie une ligne de manière unique.
- La clé étrangère référence la clé primaire d'une autre table.
- Un compte peut ne pas encore avoir de transaction, mais toute transaction doit référencer un compte existant lorsque le schéma l'exige.

5. Les quatre référentiels

Table	Grain : une ligne représente	Clé
customers	Une relation client dans une entité WABA	customer_id
accounts	Un compte, prêt, wallet ou contrat détenu par un client	account_id
branches	Une agence ou un point de service	branch_id
products	Une offre commerciale disponible dans un pays et une entité	product_id à documenter

Volumes nominaux explicitement demandés

Fichier	Nombre de lignes	Interprétation
customers.csv	500 000	Total du référentiel partagé
accounts.csv	800 000	Total du référentiel partagé
branches.csv	200	Total du référentiel partagé
products.csv	50	Total du catalogue partagé

Ces nombres sont des volumes métier attendus pour une exécution nominale. Ils ne représentent pas la capacité maximale de MinIO.

6. Clients, comptes et cohérence

customers 1 -> N accounts

Un client peut posséder plusieurs comptes. Chaque compte appartient à exactement un client par accounts.customer_id.

entity_type	account_type cohérents
BANK	CURRENT, SAVINGS, LOAN
MICROFINANCE	SAVINGS, LOAN
MOBILE_MONEY	MOBILE_WALLET
INSURANCE	INSURANCE_POLICY

credit_limit

La colonne représente le plafond de crédit autorisé. Elle vaut 0 lorsqu'elle n'est pas applicable, par exemple pour un compte d'épargne sans facilité de crédit. Une valeur positive peut être utilisée lorsqu'un compte dispose d'une autorisation de crédit.

Segments

RETAIL, SME, CORPORATE et PREMIUM décrivent le client, pas le compte. Un client RETAIL peut posséder un compte CURRENT, SAVINGS, LOAN, un wallet ou une police selon son entité WABA.

7. Les quatre tables transactionnelles

Table	Grain	Clé primaire
bank_transactions	Une tentative d'opération bancaire	transaction_id
insurance_operations	Une opération d'assurance	operation_id
mobile_money_payments	Un paiement ou transfert mobile	payment_id
loan_repayments	Une échéance ou un remboursement	repayment_id

Les transactions bancaires

account_id et beneficiary_account forment la paire débiteur-bénéficiaire. Les deux colonnes pointent vers deux rôles possibles de la même table accounts. branch_id pointe vers l'agence d'origine.

Les paiements mobile money

sender_id et receiver_id pointent directement vers customers. Le schéma fourni ne contient pas d'account_id vers un MOBILE_WALLET : nous conservons cette limite au lieu d'inventer une relation silencieuse.

8. Modèle relationnel verrouillé

Les dix relations physiques déduites des schémas fournis sont :

Parent	Enfant et rôle
customers.customer_id	accounts.customer_id
accounts.account_id	bank_transactions.account_id - débiteur
accounts.account_id	bank_transactions.beneficiary_account - bénéficiaire
branches.branch_id	bank_transactions.branch_id
customers.customer_id	insurance_operations.customer_id
accounts.account_id	insurance_operations.account_id
customers.customer_id	mobile_money_payments.sender_id - expéditeur
customers.customer_id	mobile_money_payments.receiver_id - destinataire
accounts.account_id	loan_repayments.loan_account_id
customers.customer_id	loan_repayments.customer_id

La relation client -> transaction bancaire est indirecte : customer -> account -> bank_transaction. Elle ne doit pas être matérialisée par une fausse clé étrangère customer_id dans le fichier bancaire.

9. Produit et souscription

Un type de compte est une catégorie générale. Un produit est une offre commerciale précise.

Produit commercial	account_type
Compte Essentiel	CURRENT
Épargne Avenir	SAVINGS
Prêt Conso Express	LOAN
WABA Pay Standard	MOBILE_WALLET
Assurance Auto Sérénité	INSURANCE_POLICY

Souscription

Dans le modèle envisagé, l'ouverture d'un compte ou d'un contrat matérialise une souscription. La relation métier naturelle est donc products 1 -> N accounts.

Zone d'ombre : products.csv est exigé et le Top 10 produits est demandé, mais l'annexe ne fournit ni ses attributs ni product_id dans accounts. Toute extension devra être explicitement documentée.

Schéma minimal à valider

product_id, product_name, account_type, country_code, entity_type et is_active. La relation accounts.product_id -> products.product_id reste une décision à formaliser avant modification définitive du MLD.

10. Filtres Streamlit conditionnels

L'interface ne doit pas laisser l'utilisateur choisir des combinaisons incohérentes.

Type de données	Entités proposées
REFERENCES	BANK, INSURANCE, MOBILE_MONEY, MICROFINANCE
BANK_TRANSACTIONS	BANK, MICROFINANCE
INSURANCE_OPERATIONS	INSURANCE automatiquement
MOBILE_MONEY_PAYMENTS	MOBILE_MONEY automatiquement
LOAN_REPAYMENTS	BANK, MICROFINANCE

Deux niveaux de protection

- Streamlit filtre les options pour guider l'utilisateur.
- Le backend répète toutes les validations afin qu'un script, un test ou Airflow ne puisse pas contourner les règles.

Si les références nécessaires n'existent pas pour un pays et une entité, le bouton de génération transactionnelle est désactivé et un message explique ce qui manque.

11. Volumes transactionnels

Flux	Valeur par défaut	Portée
Transactions bancaires	10 000	Par pays sélectionné
Assurance	5 000	Par pays sélectionné
Mobile money	20 000	Par pays sélectionné
Remboursements	10 000	Par pays - décision documentée

Exemple

> **10 000 lignes par pays x 3 pays = 30 000 lignes estimées**

Cette interprétation est cohérente avec la fonction indicative qui reçoit un seul country. Streamlit affichera le volume total avant confirmation.

Développement et nominal

Les petits volumes sont une facilité de test non fournie par Artefact. Une exécution nominale doit réellement atteindre 500 000 clients, 800 000 comptes, 200 agences et 50 produits. Le même code et les mêmes règles sont utilisés ; seul n_rows change.

12. Dates et reproductibilité

La période par défaut est interprétée comme trois mois glissants.

> **Application : end_date = aujourd'hui ; start_date = aujourd'hui moins trois mois**

Si l'application est utilisée le 29 septembre 2026, la période par défaut est du 29 juin au 29 septembre 2026. Le lendemain, elle se décale naturellement.

Tests

Les tests injectent une date fixe. Ils ne modifient pas la logique de production ; ils contrôlent simplement son entrée pour obtenir toujours le même résultat.

Contexte	Date de référence
Interface réelle	date.today()
Test automatisé	date(2026, 9, 29), ou autre valeur fixe du scénario

Le générateur doit aussi accepter une seed pour reproduire les distributions et scénarios de test.

13. One-time et simulation continue

Mode	Comportement
ONE_TIME	Génère immédiatement un lot, l'envoie vers MinIO et s'arrête.
CONTINUOUS	Génère un nouveau micro-lot toutes les 10 à 60 secondes jusqu'à l'arrêt demandé.

Le mode continu du Level 1 n'est pas encore Kafka. Il simule un flux temps réel par arrivée répétée de fichiers CSV.

Nommage des lots

bank_txn_CI_20260929_01.csv, puis _02.csv, _03.csv. Le numéro empêche l'écrasement et rend chaque lot traçable.

Contrôle opérationnel

- Démarrer et arrêter proprement.
- Empêcher deux générateurs identiques de fonctionner simultanément.
- Afficher le nombre de lots et lignes générés.
- Ne pas exécuter une boucle infinie non contrôlée dans la page Streamlit.

14. MinIO et organisation des fichiers

MinIO stocke les fichiers comme des objets. Les volumes métier ne sont pas des limites de stockage.

Bucket	Rôle
raw-landing	Fichiers CSV reçus et non encore traités
lakehouse	Fichiers et métadonnées des tables Iceberg
archive	Fichiers déplacés après ingestion réussie

Organisation proposée

Référentiels sous references/type ; transactions sous transactions/country_code=XX/data_type. La convention exacte sera utilisée par le générateur, Spark et les tests.

> **Un fichier ne doit être archivé qu'après validation et écriture Iceberg réussies.**

Pour les gros volumes, le CSV sera écrit progressivement dans un fichier temporaire, envoyé vers MinIO, puis supprimé localement après succès.

15. Contrats de données et validations

Chaque table doit disposer d'un contrat indiquant le nom, le type, la nullabilité, les valeurs autorisées, les clés, les règles et un exemple.

Validation	Exemple
Unicité	transaction_id ne doit apparaître qu'une fois
Référentielle	loan_account_id existe dans accounts
Type métier	loan_account_id référence account_type=LOAN
Propriété	le compte de prêt appartient au customer_id
Pays-devise	GH -> GHS ; pays UEMOA du challenge -> XOF
Fichier-contenu	bank_txn_CI contient country_code=CI
Temporalité	timestamp est dans la période demandée
Conditionnelle	claim_status est NULL hors sinistre

Les filtres Streamlit réduisent les erreurs, mais ces règles sont implémentées dans le backend et testées indépendamment.

16. Exigence, décision et hypothèse

Nature	Exemples
Exigence explicite	Huit tables, volumes nominaux, pays, entités, modes, MinIO et schémas fournis
Décision documentée	10 000 remboursements par pays ; trois mois glissants ; filtres conditionnels
Hypothèse à verrouiller	Schéma products et relation product_id avec accounts
Facilité technique	Petits volumes de test ; date fixe injectée dans les tests

Ordre de construction

- 1. Finaliser products et les contrats de données.
- 2. Configurer MinIO et les trois buckets.
- 3. Construire le générateur de référentiels.
- 4. Construire les générateurs transactionnels depuis les références.
- 5. Ajouter l'upload et le mode one-time.
- 6. Ajouter le mode continu contrôlé.
- 7. Brancher Streamlit sur le moteur testé.

Le modèle et les règles sont construits avant l'interface afin que Streamlit ne masque pas une logique métier incorrecte.