PLAN D'EXECUTION

Video de demonstration - Challenge Data Engineer

Objectif
Produire une video claire de 5 a 10 minutes prouvant le fonctionnement des Levels 1 a 3, sans montrer de secret et sans attendre inutilement devant l'ecran.

Support mobile a suivre pendant l'enregistrement

1. Pourquoi plusieurs captures courtes ?

Definition simple
Une capture courte est un petit fichier video consacre a une seule preuve. Tu enregistres, par exemple, Streamlit pendant 45 secondes, tu arretes, puis tu enregistres Airflow dans un nouveau fichier.

Exemple concret

- 01_architecture.mp4 : 25 secondes sur le schema.
- 02_streamlit_minio.mp4 : generation puis apparition du CSV dans MinIO.
- 03_airflow.mp4 : declenchement du DAG, puis resultat final vert.
- 04_trino_batch.mp4 : execution d'une requete et affichage des lignes Gold.
- 05_streaming_alertes.mp4 : NiFi, topics Kafka et alerte fraude.
- 06_lambda_trino.mp4 : requete historique + temps reel.

Pourquoi c'est preferable

- Tu peux recommencer uniquement la sequence ratee.
- Tu supprimes les temps d'attente de Spark ou Airflow au montage.
- Tu gardes une video finale fluide et inferieure a 10 minutes.
- Tu ne caches pas le fonctionnement : tu montres l'action, puis son resultat reel.

Montage final
Importe tous les clips dans Microsoft Clipchamp, place-les dans l'ordre, coupe les attentes et ajoute seulement quelques cartouches de texte. Exporte en 1080p.

2. Chronologie cible de la video

Temps	Sequence	Preuve
0:00-0:30	Architecture et perimetre	Levels 1 a 3, batch + streaming
0:30-1:30	Streamlit et MinIO	Generation multi-pays et depot raw-landing
1:30-2:40	Airflow batch	DAG Raw -> Bronze -> Silver -> Gold
2:40-3:20	Trino batch	Table Gold interrogeable en SQL
3:20-4:45	NiFi, Kafka, Spark	CSV -> evenements Raw -> Silver
4:45-5:40	Fraude / AML	Alerte produite dans un topic Gold
5:40-6:50	Architecture Lambda	Iceberg historique + Kafka frais
6:50-7:15	Conclusion	Perimetre, resultat et limites

TEXTE A L'ECRAN : Plateforme financiere multi-pays - demo fonctionnelle Levels 1 a 3

La duree cible est de 7 minutes environ. Elle respecte la demande de 5 a 10 minutes et laisse une petite marge.

3. Preparation avant d'enregistrer

A. Verifier les fichiers locaux

- Le fichier .env existe localement, mais il ne doit jamais apparaitre dans la video.
- Les identifiants, mots de passe et valeurs sensibles sont masques.
- Les contrats Trino et le flow NiFi exporte sont presents dans le depot.

B. Demarrer et controler la stack

```
docker compose up -d --build
docker compose ps -a
```

- Attendu : services principaux Running/Healthy ; minio_init peut etre Exited (0).

C. Ouvrir les ecrans avant la capture

- Streamlit : http://localhost:8501
- MinIO : http://localhost:9001
- Airflow : http://localhost:8081
- Spark Master : http://localhost:8082
- NiFi : https://localhost:8443/nifi

D. Preparer une fenetre terminal propre

- Augmente la taille de police et nettoie le terminal avec clear.
- Prepare les commandes dans un fichier texte pour les copier sans faute.
- Ferme les onglets, notifications et applications personnelles.

Point important NiFi
ListS3 memorise les objets deja vus. Pour chaque demonstration streaming, utilise un nouveau nom de fichier, par exemple bank_txn_CI_20261010_01.csv puis ..._02.csv.

4. Commandes streaming a preparer

Job 1 - Raw Kafka vers Silver

```
docker compose exec -T airflow-scheduler spark-submit \
 --master spark://spark-master:7077 \
 --deploy-mode client \
 --conf spark.driver.bindAddress=0.0.0.0 \
 --conf spark.driver.host=airflow-scheduler \
 /opt/airflow/spark/jobs/streaming_job_raw_to_silver.py \
 --table bank_transactions
```

Job 2 - Silver Kafka vers alertes Gold

```
docker compose exec -T airflow-scheduler spark-submit \
 --master spark://spark-master:7077 \
 --deploy-mode client \
 --conf spark.driver.bindAddress=0.0.0.0 \
 --conf spark.driver.host=airflow-scheduler \
 /opt/airflow/spark/jobs/streaming_job_silver_to_gold.py \
 --table bank_transactions
```

Ordre
Lance d'abord le Job 1, puis le Job 2. Verifie dans Spark Master que les deux applications sont Running avant de deposer le nouveau CSV.

5. Clip 1 - Architecture

Duree cible : 20 a 30 secondes.

Ce que tu montres

- La slide d'architecture complete, sans lire tous les composants.
- Tu suis visuellement les deux chemins : batch dans le Lakehouse et streaming dans Kafka.

Texte a afficher successivement

TEXTE A L'ECRAN : Batch : Streamlit -> MinIO -> Spark/Iceberg -> Bronze/Silver/Gold

TEXTE A L'ECRAN : Streaming : MinIO -> NiFi -> Kafka -> Spark Structured Streaming

TEXTE A L'ECRAN : Trino unifie l'historique Iceberg et les donnees recentes Kafka

Point a faire comprendre

La plateforme traite les memes domaines financiers en batch et en quasi-temps reel. Le perimetre livre et demontre correspond aux Levels 1, 2 et 3.

6. Clip 2 - Generation multi-pays

Duree cible : 50 a 70 secondes.

Action dans Streamlit

- Selectionne un type de donnees, par exemple Transactions bancaires.
- Selectionne au moins deux pays, par exemple CI et SN.
- Choisis BANK, un petit volume de demonstration et le mode One-time.
- Lance la generation et montre le message de succes.

Preuve dans MinIO

- Ouvre raw-landing et montre les nouveaux CSV organises par pays/type.
- Ouvre rapidement un objet ou son nom pour prouver la nomenclature.

TEXTE A L'ECRAN : Generation fictive multi-pays - validation Avro - depot dans raw-landing

A ne pas faire
Ne genere pas les volumes nominaux pendant la video. Un petit volume suffit a prouver le flux ; les volumes complets restent configurables.

7. Clip 3 - Pipeline batch Airflow

Duree cible : 60 a 80 secondes apres coupe des attentes.

Action

- Ouvre dag_ingest_raw dans Airflow.
- Declenche un Single Run avec un country_code explicite, par exemple CI.
- Filme 10 a 15 secondes le graphe qui demarre, puis arrete la capture.
- Quand le pipeline est termine, enregistre un second clip du graphe vert.

Preuves a cadrer

- Dependances explicites entre referentiels et transactions.
- Declenchement de Bronze vers Silver, puis Silver vers Gold.
- Retries visibles dans la configuration ou l'interface si utile.

TEXTE A L'ECRAN : Orchestration parametree par pays - dependances, retries et traitements Spark

Pourquoi deux captures ?
Le traitement peut durer plusieurs minutes. Le montage rapproche le declenchement et le resultat final sans faire attendre l'evaluateur.

8. Clip 4 - Requete Trino batch

Duree cible : 30 a 45 secondes.

```
docker compose exec trino trino \
 --server http://localhost:8080 \
 --user waba \
 --execute "SELECT * FROM data.gold.daily_transaction_volume LIMIT 10"
```

Ce que le resultat prouve

- Les tables Iceberg sont partagees via le catalogue REST.
- Trino voit le schema Gold et peut interroger les KPI en SQL.
- Les colonnes pays, entite, type de transaction, volume et montant EUR sont visibles.

TEXTE A L'ECRAN : Tables Iceberg Gold accessibles en SQL via Trino

9. Clip 5 - Flux streaming

Duree cible : 70 a 90 secondes.

Avant de deposer le fichier

- NiFi Process Group est Running.
- Les Jobs Spark 1 et 2 sont Running dans Spark Master.
- Le fichier de test utilise des identifiants presents dans les referentiels.

Action et preuves

- Depose dans raw-landing un CSV bancaire avec un nom jamais utilise.
- Montre NiFi : ListS3 -> routage -> FetchS3 -> CSV/JSON -> metadata -> split -> Kafka.
- Montre le compteur du topic Silver ou consomme quelques messages.

```
docker compose exec broker kafka-console-consumer \
 --bootstrap-server broker:29092 \
 --topic silver-bank-transactions \
 --from-beginning --timeout-ms 10000
```

TEXTE A L'ECRAN : Un CSV devient une suite d'evenements JSON enrichis et valides

10. Clip 6 - Alerte fraude / AML

Duree cible : 40 a 60 secondes.

Jeu de demonstration recommande

- Plusieurs transactions du meme compte dans une fenetre de 5 minutes.
- Montant cumule superieur a 500 000 XOF pour la regle de fraude.
- Ou un virement au-dessus du seuil declaratif pour l'alerte AML.

Lecture via Trino

```
docker compose exec trino trino \
 --server http://localhost:8080 --user waba \
 --execute 'SELECT alert_type, detected_at, country_code, account_id, total_amount FROM
kafka.default."gold-fraud-alerts" LIMIT 10'
```

TEXTE A L'ECRAN : Detection quasi-temps reel : fraude, AML et liquidite

Resultat attendu
Au moins une alerte lisible avec son type, le pays, le compte concerne, la fenetre et le montant. Ne te contente pas de montrer seulement le nombre de messages.

11. Clip 7 - Requete Lambda unifiee

Duree cible : 50 a 70 secondes.

Vue detaillee

```
docker compose exec -T trino trino \
 --server http://localhost:8080 --user waba \
 < trino/query/lambda_bank_transaction/lambda_bank_transactions_detail.sql
```

Vue globale

```
docker compose exec -T trino trino \
 --server http://localhost:8080 --user waba \
 < trino/query/lambda_bank_transaction/lambda_transactions_global.sql
```

Comment lire le resultat

- Historique : donnees Gold Iceberg anterieures a aujourd'hui.
- Frais : transactions Silver Kafka du jour courant.
- La requete produit une vision SQL unique par date, pays, entite et type de transaction.

TEXTE A L'ECRAN : Architecture Lambda : historique Iceberg + donnees fraiches Kafka

12. Clip 8 - Conclusion

Duree cible : 20 a 30 secondes.

Slide finale conseillee

- Socle Lakehouse batch reproductible et interrogeable.
- Orchestration Airflow avec dependances, retries et parametre pays.
- Streaming NiFi/Kafka/Spark avec DLQ et alertes metier.
- Acces unifie via Trino selon le pattern Lambda.

Limites a annoncer simplement

- Perimetre livre : Levels 1 a 3 ; Level 4 non implemente.
- Taux de change statiques et regle de liquidite simplifiee/documentee.
- Deploiement local mono-instance, sans TLS interservices.
- Archivage automatique des CSV traites non implemente.

TEXTE A L'ECRAN : Livraison volontairement centree sur un Level 3 fonctionnel, explicable et reproductible

13. Montage simple avec Clipchamp

- Ouvre Clipchamp et cree une nouvelle video 16:9.
- Importe les clips 01 a 08 et place-les dans l'ordre.
- Coupe le debut, la fin et les attentes avec l'outil de decoupage.
- Ajoute un titre court au debut de chaque sequence ; pas de paragraphes.
- Ajoute des zooms uniquement si une sortie terminal est trop petite.
- Garde les resultats affiches 3 a 5 secondes pour qu'ils soient lisibles.
- Exporte en MP4 1080p et verifie la duree finale.

Sans voix off

Ta solution est acceptable : les cartouches de texte remplacent la narration. Ils doivent expliquer l'action et la preuve, pas tout le code.

Avec voix off plus tard

Tu peux conserver les memes clips et ajouter une narration tres courte. Aucun besoin de refaire la demonstration.

Regle de montage
Une sequence = une idee. Si un clip ne prouve rien de nouveau, supprime-le.

14. Checklist finale

- [ ] La video dure entre 5 et 10 minutes.
- [ ] La generation multi-pays est visible.
- [ ] Le depot dans raw-landing est visible.
- [ ] Le pipeline Airflow est declenche et termine.
- [ ] Une table Gold est interrogee via Trino.
- [ ] NiFi publie des evenements dans Kafka.
- [ ] Les Jobs Spark streaming sont Running.
- [ ] Une alerte fraude ou AML est affichee.
- [ ] La requete Lambda combine Iceberg et Kafka.
- [ ] Aucun secret ni fichier .env n'est visible.
- [ ] Le perimetre Levels 1 a 3 et les limites sont annonces.
- [ ] Le MP4 final a ete regarde une fois du debut a la fin.

Ordre de livraison
1. Depot Git - 2. README - 3. PDF de choix d'architecture - 4. Video MP4 - 5. Note de soumission avec les liens.